

## **Supervisão de hábitos alimentares em grupos de animais com visão computacional em raspberry Pi**

### **Supervision of feeding habits in groups of animals with computer vision on raspberry Pi**

### **Supervision of feeding habits in groups of animals with computer vision on raspberry Pi**

DOI:10.34117/bjdv10n5-051

Submitted: Apr 19<sup>th</sup>, 2024

Approved: May 10<sup>th</sup>, 2024

#### **Diego Tefili**

Mestre em Engenharia Elétrica  
Instituição: Instituto Federal do Paraná (IFPR)  
Endereço: Campo Largo, Paraná, Brasil  
E-mail: diego.tefili@ifpr.edu.br

#### **Marcos Santos Hara**

Doutor em Engenharia Biomédica  
Instituição: Instituto Federal do Paraná (IFPR)  
Endereço: Campo Largo, Paraná, Brasil  
E-mail: marcos.hara@ifpr.edu.br

#### **Beatriz dos Santos Pês**

Doutora em Engenharia Elétrica  
Instituição: Instituto Federal do Paraná (IFPR)  
Endereço: Campo Largo, Paraná, Brasil  
E-mail: beatriz.santos@ifpr.edu.br

#### **Anderson Felipe Moreira Ribeiro**

Técnico em Automação  
Instituição: Universidade Tecnológica Federal do Paraná (UTFPR)  
Endereço: Curitiba, Paraná, Brasil  
E-mail: andersonfelipe1801@gmail.com

#### **Jayane Wiezbicki**

Técnica em Automação  
Instituição: Instituto Federal do Paraná (IFPR)  
Endereço: Campo Largo, Paraná, Brasil  
E-mail: jayane.wiezb@gmail.com

#### **Nevton Cajé Lima Filho**

Técnico em Automação  
Instituição: Instituto Federal do Paraná (IFPR)  
Endereço: Campo Largo, Paraná, Brasil  
E-mail: nevtoninho@gmail.com

## RESUMO

A modernização do setor da pecuária no Brasil tem ocorrido de maneira intensa, de modo a buscar maior eficiência na produção em um menor intervalo de tempo. Nessa perspectiva, a análise do comportamento alimentar de indivíduos em rebanhos possui extrema importância, haja vista que alterações no padrão alimentar dos animais podem inferir sobre problemas sociais ou de saúde, causando perda na eficiência do processo de ganho de massa. Nessa perspectiva, o presente trabalho de conclusão de curso teve como proposta, por parte dos estudantes do ensino médio técnico em Automação Industrial, desenvolver um protótipo que auxilie na identificação e controle dos comportamentos alimentares de suínos, a fim de realizar uma análise dos dados coletados e encontrar possíveis padrões. Para o desenvolvimento do projeto, as seguintes etapas foram realizadas: configuração da placa de desenvolvimento Raspberry Pi, aprendizagem do sistema Linux, estudo das bibliotecas de visão computacional OpenCV e TensorFlow, aprimoramento do código-base utilizado, redirecionando-o para os objetivos do trabalho e geração de relatórios. Com isso, concluiu-se que é possível realizar estudos sobre o comportamento alimentar de indivíduos a partir da visão computacional.

**Palavras-chave:** visão computacional, Raspberry Pi, suínos, comportamento alimentar.

## ABSTRACT

The modernization of the livestock sector in Brazil has been taking place in an intense manner, in order to seek greater efficiency in production in a shorter period of time. From this perspective, the analysis of the feeding behavior of individuals in herds is extremely important, given that changes in the feeding pattern of animals can infer social or health problems, causing a loss in the efficiency of the mass gain process. With this in mind, the aim of this end-of-course project was for high school students studying Industrial Automation to develop a prototype to help identify and control the feeding behavior of pigs, in order to analyze the data collected and find possible patterns. To develop the project, the following steps were taken: configuring the Raspberry Pi development board, learning the Linux system, studying the OpenCV and TensorFlow computer vision libraries, improving the basic code used, redirecting it to the objectives of the work and generating reports. With this, it has been concluded that it is possible to carry out studies on the feeding behavior of individuals from the computational vision.

**Keywords:** computer vision, Raspberry Pi, pigs, feeding behavior.

## RESUMEN

La modernización del sector pecuario en Brasil ha sido intensa, con el objetivo de alcanzar una mayor eficiencia productiva en un menor período de tiempo. Desde esta perspectiva, es de extrema importancia analizar el comportamiento alimentario de los individuos de los rebaños, dado que alteraciones en los patrones alimentarios de los animales pueden acarrear problemas sociales o sanitarios, provocando una pérdida de eficiencia en el proceso de ganancia de masa. Teniendo esto en cuenta, el objetivo de este proyecto fin de carrera era que los alumnos de bachillerato de la asignatura de Automatización Industrial desarrollaran un prototipo que ayudara a identificar y controlar el comportamiento alimentario de los cerdos, con el fin de analizar los datos recogidos y encontrar posibles patrones. Para el desarrollo del proyecto se siguieron los siguientes pasos: configuración de la placa de desarrollo Raspberry Pi, aprendizaje del sistema Linux, estudio de las librerías de visión por computador OpenCV y TensorFlow, mejora del código básico utilizado, reorientación del mismo a los objetivos del trabajo y generación de informes.

Como resultado, se concluyó que es posible realizar estudios sobre el comportamiento alimentario de los individuos utilizando visión por computador.

**Palabras clave:** visión por computador, Raspberry Pi, cerdos, comportamiento alimentario.

## 1 INTRODUÇÃO

O emprego de diferentes tecnologias na pecuária brasileira tem proporcionado uma modernização do setor e um elevado aumento da produtividade em intervalos de tempo reduzidos. A causa desse processo tem forte relação com o crescimento das demandas de exportação e de consumo de carne no país. De acordo com dados da Empresa Brasileira de Pesquisa Agropecuária (Embrapa, 2022), a produção de carne de aves aumentou 22 vezes e as de carne suína e bovina, 4 vezes nos últimos 40 anos.

Além disso, a demanda do mercado consumidor pelo bem-estar animal está em constante crescimento. Dado que é responsabilidade do produtor assegurar os cuidados e manuseio adequados dos animais no criadouro até a entrega ao abatedouro, o estudo do comportamento de indivíduos em rebanhos é de extrema importância para o ramo da pecuária, visto também que a observação dos hábitos desses animais pode transparecer problemas sociais ou doenças. No caso do comportamento alimentar, há pesquisas que mostram o efeito da alteração dessa rotina na saúde e no ganho de massa dos indivíduos, reduzindo a eficiência do manejo e, consequentemente, aumentando o tempo de criação, gerando também prejuízos econômicos (BROWN-BRANDL, 2013).

Inicialmente, os estudos eram realizados com os suínos alojados individualmente. No entanto, a análise dos resultados era comprometida pelo fator social, visto que não havia interação entre os indivíduos durante a alimentação. Com isso, a primeira evolução visava a possibilidade de análise do hábito alimentar de animais em rebanhos (YOUNG & LAWRENCE, 1994).

Young e Lawrence, num estudo publicado em 1994, utilizam de um sistema computadorizado com tecnologia de reconhecimento individual através de alimentadores computadorizados (CFIR, sigla em inglês para Computerized Food Intake Recording) e etiquetas inseridas nas orelhas dos animais para obter registros alimentares de cada indivíduo e assim analisar o comportamento na ingestão de

alimentos de suínos confinados em grupos. Com isso, os autores obtêm dados e informações que concluem que fatores sociais têm impacto considerável sobre o comportamento alimentar.

Além disso, existem artigos escritos com base no registro dessas informações por meio de etiquetas e leitores de identificação por radiofrequência que também evidenciam os mesmos resultados. Brown-Brandl et al. (2013) descrevem em seu artigo o desenvolvimento de um sistema RFID (Radio-Frequency Identification) para registrar o comportamento alimentar em grupos de suínos e analisar impactos sociais e de saúde sobre esse hábito. Maselyne et al. (2016) também trazem um estudo por meio da utilização das etiquetas de radiofrequência, enfatizando as alterações do padrão alimentar como consequência de doenças ou mudanças no bem-estar animal.

Porém, a utilização desses dispositivos no monitoramento de animais que compartilham o mesmo recipiente de alimentação pode apresentar fatores negativos, como estresse aos indivíduos e possibilidade de danos e extravios dos equipamentos no local de criação. Dessa forma, se faz necessária a utilização de métodos para realizar o registro do hábito alimentar de cada indivíduo de uma maneira mais precisa, eficaz e confiável.

Zhang et al. (2019) desenvolveram um projeto para detecção e rastreamento individual de suínos confinados em grupos por meio de uma câmera 2D e algoritmos de visão computacional. Com esse método, não há necessidade de marcação física nos animais confinados. Após testarem três diferentes estruturas de detecção, os autores concluíram que o formato SSD (Single-Shot Detection) é o que melhor realiza as detecções dos suínos.

Com isso, o projeto descrito neste capítulo teve como objetivo desenvolver um método de reconhecimento e diferenciação de indivíduos por meio de visão computacional. Esse processo foi realizado a partir da implementação e desenvolvimento de um algoritmo SSD (sigla em inglês para Detecção de Disparo Único) com as bibliotecas de programação TensorFlow e OpenCV em uma placa de desenvolvimento Raspberry Pi. A partir disso, o programa gerou alertas e relatórios com os padrões de comportamento de cada indivíduo. Este protótipo foi desenvolvido como um trabalho de conclusão de curso técnico em automação por estudantes de ensino médio.

## **2 REVISÃO BIBLIOGRÁFICA**

### **2.1 COMPORTAMENTO ALIMENTAR**

O comportamento alimentar contém informações importantes que podem permitir que os produtores gerenciem melhor o gado. Da mesma forma, pesquisadores podem se beneficiar ao compreender melhor os fatores que influenciam a ingestão de alimentos (BROWN-BRANDL, 2013). Além disso, a observação do efeito de tratamentos e a investigação ou previsão de doenças também se tornam possíveis a partir dessas informações.

Diversos estudos incluem parâmetros de comportamento alimentar em suínos, como: quantidade de ração ingerida, duração da refeição, intervalo entre refeições, número de refeições por dia, tempo total gasto em alimentação e taxa de ingestão (BROWN-BRAND, 2013; YOUNG & LAWRENCE, 1994; AMANDA J. CROSS, 2020).

Variados sistemas e técnicas com o objetivo de medir o consumo de ração de bovinos, suínos e aves confinados em grupos foram criados nos últimos anos. No entanto, a maioria desses métodos exige que o animal esteja isolado no alimentador, desviando os resultados da coleta de informações, visto que o indivíduo passa a não ter interação social no momento da refeição e, principalmente, tornando a utilização desses sistemas inviáveis em grande escala.

No entanto, alguns estudos sobre o comportamento alimentar em casos de alojamento e alimentação em grupo têm sido realizados de diferentes maneiras, evidenciando a possibilidade da análise desse hábito de uma forma mais compatível com a pecuária comercial. Young e Lawrence (1994) mostraram em seu estudo um sistema que utiliza tecnologia para o reconhecimento individual, tornando possível o registro preciso do comportamento alimentar de cada indivíduo em condições de alojamento em grupo, sem que haja necessidade de isolamento. Esses sistemas de registro computadorizado da ingestão de alimentos geralmente fornecem um único alimentador para grupos de 10 a 14 indivíduos. Além disso, esse método possibilita que o alimentador seja compartilhado, fazendo com que não sejam excluídos dos resultados os efeitos dos conflitos sociais no momento da alimentação.

Brown-Brandl, Rohrer e Eigenberg (2013) desenvolveram um sistema com etiquetas RFID (Radio-Frequency Identification) em suínos para o registro e a análise

do comportamento alimentar. Dentre diversos aspectos observados no estudo, foram enfatizados a relação entre tempo gasto no alimentador e idade do animal, o impacto do período gasto em ingestão no ganho de massa e a diferença de tempo em alimentação entre machos e fêmeas. Com esses dados, o estudo mostra o potencial de utilização do comportamento alimentar para o aumento de eficiência no manejo de suínos em um ambiente comercial.

## 2.2 RASPBERRY PI

Raspberry Pi é uma série de minicomputadores de código aberto. O equipamento foi criado em 2012 e é desenvolvido por uma fundação do Reino Unido com a intenção de facilitar o aprendizado na ciência da computação. Apesar de seu tamanho reduzido, uma Raspberry Pi pode possuir um poder de processamento semelhante ao de um computador pessoal. Além disso, o suporte a protocolos, a possibilidade de conexões avançadas e os diversos componentes integrados tornam a placa de desenvolvimento mais completa que as placas Arduino, podendo ser utilizada na aprendizagem de programação e robótica, como substituta de um computador ou *notebook*, em projetos de automação residencial ou até aplicações industriais (TECHMOB, 2018; TECMUNDO, 2022).

## 2.3 INTELIGÊNCIA ARTIFICIAL

A Inteligência Artificial (IA) é um ramo da ciência da computação e consiste em sistemas ou máquinas que, por meio de símbolos computacionais, imitam a inteligência humana para realizarem tarefas. Além disso, esses dispositivos podem construir mecanismos e passar por aprimoramentos iterativos com base em informações coletadas. Dessa forma, a inteligência artificial está intrinsecamente relacionada ao processo e à capacidade de automatizar processos de inferência com o intuito de resolver problemas.

A IA tem evoluído de forma expressiva ao longo dos anos e tem sido fortemente encorajada no mundo empresarial, nas sociedades e nas organizações, perspectivando as suas possíveis e diversas aplicações (RAIMUNDO e SEBASTIÃO, 2021). Pode ser observada a inteligência artificial associada à robótica sendo empregada na indústria automobilística, como na montagem de carros, em carros autônomos que utilizam da

visão computacional para não dependerem da ação do motorista, em dispositivos inteligentes e assistentes virtuais para a automação residencial (como a Alexa da Amazon e a Siri da Apple), entre outras ferramentas. Dessa forma, é notório que a IA está em constante crescimento e evolução, sendo cada vez mais utilizada para as mais diversas funcionalidades.

## 2.4 APLICAÇÃO DA INTELIGÊNCIA ARTIFICIAL NA AUTOMAÇÃO INDUSTRIAL

Nos dias atuais, com a chegada da quarta revolução industrial, conhecida pela expressão “Indústria 4.0”, as empresas encaram desafios relacionados à demanda, redução de custos e à competitividade global, o que exige adaptações. Com isso, espera-se um crescimento do uso da automação industrial baseada em IA (TELLES, 2020), pois seu uso em sistemas de produção, além de encurtar os ciclos de desenvolvimento, previne falhas, aumenta a segurança, permite um melhor abastecimento e planejamento de demanda, promove uma melhoria nos resultados e conseqüentemente um aumento de eficiência (BUGHIN, 2017).

De acordo com Qiyao (2021):

“A inteligência artificial ainda apresenta muitas limitações no sistema de controle de automação industrial, evidenciando a necessidade de aplicação da tecnologia da IA por parte de especialistas e acadêmicos com base nas características e necessidades reais da automação industrial, de modo a melhorar o seu desempenho”.

## 2.5 VISÃO COMPUTACIONAL

Visão computacional é uma ciência recente, com esse termo tendo sido mencionado pela primeira vez em 1955 por Selfridge ‘...eyes and ears for the computer’. Tratada como uma ramificação da inteligência artificial voltada para emular a visão humana, é responsável pela forma como o computador enxerga o meio a sua volta, extraindo informações significativas a partir de imagens capturadas por câmeras de vídeo, sensores, *scanners* e outros dispositivos (MILANO & HONORATO, 2010). Essas informações permitem reconhecer, manipular e extrair informações sobre os objetos que compõem uma imagem. Dessa forma, a visão computacional pode ser vista como um sistema que possui como entrada uma imagem e como saída sua interpretação



total ou parcial (MARENGONI & STRINGHINI, 2009). Esse processo ocorre por meio de redes neurais artificiais, que são sistemas computacionais que funcionam de forma semelhante à estrutura neural de seres humanos.

De forma simplificada, as redes neurais são divididas em três repartições: uma camada de entrada, na qual os padrões são apresentados, uma ou mais camadas ocultas, onde é realizada a maior parte do processamento, e uma camada de saída, na qual é concluído e apresentado o resultado.

Algoritmos de visão computacional têm sido utilizados para diversas funcionalidades, como para identificação facial, detecção de animais (SANTOSO, 2021), objetos (KUZMIC & RUDOLPH, 2021), pessoas (HARTAWAN, 2019; NORMAN, 2022), veículos (ZURAIMI & ZAMAN, 2021), ervas e sementes (CHECHLINSKI 2019), entre outras aplicações. Em diversos projetos como esses, são utilizadas bibliotecas e compilações de programas das plataformas TensorFlow e OpenCV.

### **3 METODOLOGIA**

Esta seção detalha as bibliotecas utilizadas e a elaboração do algoritmo.

#### **3.1 PLACA RASPBERRY PI**

Neste projeto, foi utilizada uma Raspberry Pi 4 model B com 4Gb RAM. A placa conta com as seguintes entradas/saídas: uma entrada de fonte de energia USB-C; dois conectores Micro HDMI, com possibilidade de acoplamento a dois monitores com resolução 4K; duas portas USB 2.0 e outras duas USB 3.0; porta Ethernet; slot para cartão de memória SD; conector de saída de áudio analógico. Além disso, a Raspberry Pi 4 possui também 40 pinos de entrada e saída de uso geral (GPIO) e conectores de interface serial de display (DSI) e câmera (CSI). Para o projeto em questão, uma placa Raspberry apresenta-se como mais adequada do que um computador convencional, já que esta pode ser mais facilmente instalada em um ambiente de criação de animais por ser compacta e leve, podendo até ser instalada no teto.



### 3.2 OPENCV

OpenCV (*Open Source Computer Vision*) é uma biblioteca de programação de código aberto, desenvolvida inicialmente pela Intel Corporation. Criado com o objetivo de tornar a visão computacional acessível a usuários e programadores para a utilização na interação humano-máquina e na robótica, o OpenCV integra uma variedade de ferramentas para a visão computacional, desde os processos mais simples, como um filtro de ruído, até os mais complexos, como a análise de movimentos e reconhecimento de padrões (MARENGONI & STRINGHINI, 2009).

Por ser uma compilação de código aberto, é possível encontrar diversos tutoriais e documentações na Internet. No presente projeto, a biblioteca OpenCV foi utilizada na captura e tratamento de imagens.

### 3.3 TENSORFLOW

A plataforma TensorFlow foi desenvolvida especialmente para utilização em visão computacional, possui alta flexibilidade e pode ser executada localmente em um computador. Para identificar um objeto, é necessário o treinamento do sistema com uma quantidade considerável de imagens. Este processo requer grande esforço computacional, e pode ser feito mais rapidamente, por exemplo, em computadores virtuais em servidores do Google. Depois do treinamento, o processo de reconhecimento do objeto pode ser feito localmente em um computador.

O TensorFlow é considerado a plataforma mais dominante e relevante na área de visão computacional (DINGHOFER & HARTUNG, 2020), possui vasta documentação online e diversos tutoriais, normalmente enfatizados em aplicações industriais ou no ensino básico do ramo. Além disso, essa plataforma pode ser utilizada em dispositivos com recursos limitados como smartphones e placas Raspberry Pi (KUZMIC & RUDOLPH, 2021).

### 3.4 MOBILENET

MobileNet é uma classe de modelos eficientes para dispositivos móveis e visão embarcada, baseada em uma arquitetura simplificada que utiliza de convoluções separáveis em profundidade para construir redes neurais artificiais profundas e leves

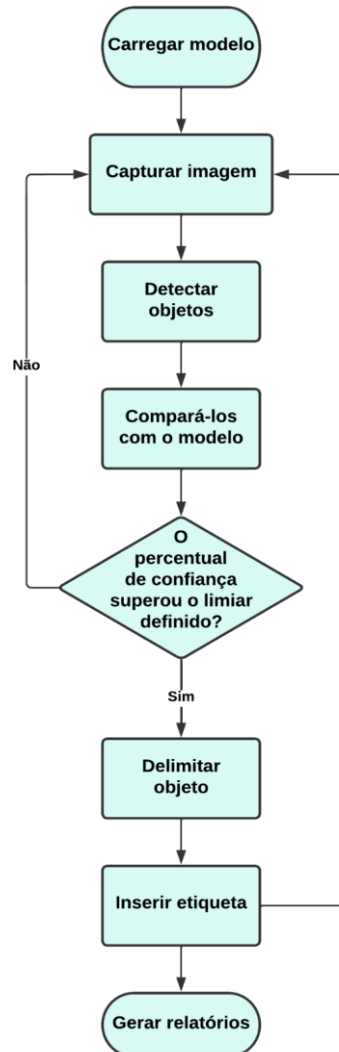
(Howard et al., 2017). Esse modelo conta com 80 objetos detectáveis, entre eles: pessoas, carros, objetos pequenos como teclados e *mouses* e animais como vacas, cavalos e ovelhas.

### 3.5 PROGRAMAÇÃO

O programa criado foi a partir de uma adaptação de um código aberto fornecido pelo site Q-Engineering (2022). Em se tratando de estudos de visão computacional, a linguagem de programação mais comum é Python devido à sua facilidade de uso e ampla documentação online. No entanto, por ser uma linguagem interpretada e não compilada, pode apresentar menor desempenho para detecção em tempo real. Diferentemente, o código aberto no qual este projeto se inspirou utiliza C++, uma linguagem compilada.

Após o mapeamento do código original e dos principais funções das bibliotecas de visão computacional, foi elaborado um fluxograma das ações a serem realizadas pelo programa visando a identificação dos animais e a projeção de identificadores sobre a imagem, conforme a Figura 1.

Figura 1: Fluxograma das principais etapas do código



Fonte: Os autores

O modelo MobileNet recebe as imagens, processa-as, detecta os objetos na imagem e infere um índice de semelhança de 0 a 1 que representa o quanto o objeto detectado se parece com o modelo de cada objeto conhecido. O programa então faz uma classificação e compara estes índices a um limiar de confiança ajustável. Quanto maior o limiar de confiança, maior é a precisão nas detecções e menos objetos são detectados erroneamente. Ou seja, essa variável trata do percentual mínimo de certeza que o programa deve possuir se o objeto detectado é semelhante ao modelo comparado.

O programa foi alterado para utilizar o relógio do sistema operacional para inserir na imagem as informações de data e hora que viriam a ser utilizadas para a geração de relatórios de eventos, como detalhado na Figura 2.

Figura 2: Recorte do código com a função de horário

```
f = chrono::duration_cast <chrono::milliseconds> (Tend - Tbegin).count();
if(f>0.0)
    FPS[((Fcmt++)&0x0F)]=1000.0/f;
for(f=0.0, i=0; i<16; i++)
{
    f+=FPS[i];
}
struct tm *data_hora_atual;
time_t t = time(NULL);
data_hora_atual = localtime(&t);
putText(frame, format("FPS %0.2f", f/16), Point(10, 20),
        FONT_HERSHEY_SIMPLEX, 0.6, Scalar(0, 0, 255), 2);
putText(frame, format("%s", asctime (data_hora_atual)), Point(370, 20),
        FONT_HERSHEY_SIMPLEX, 0.6, Scalar(255, 255, 255), 2);
```


→ Cria a estrutura do horário

→ Insere o horário no vídeo

Fonte: autores

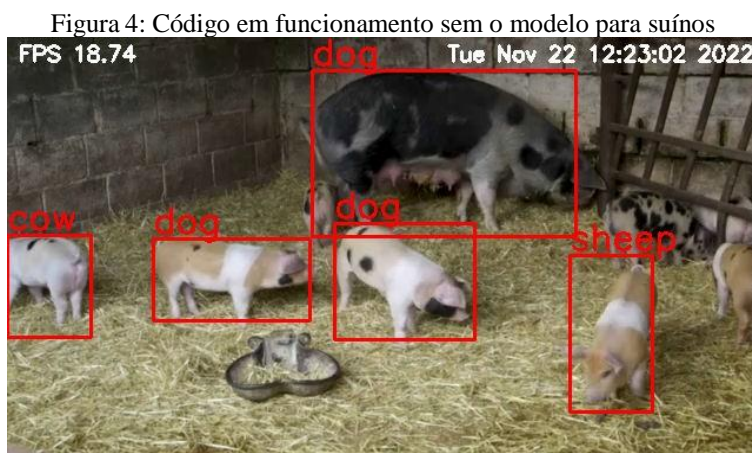
O resultado desta operação é mostrado na Figura 3, com o horário sendo exibido no cabeçalho do vídeo.

Figura 3: Código com a função horário em funcionamento



Fonte: autores

Além disso, após testar o código em vídeos de animais em rebanhos, nos deparamos com a ausência de uma classe para entre os objetos detectáveis pelo modelo MobileNet (como mostrado na Figura 4), nosso objeto de estudo, identificando esses animais como outros semelhantes. Por isso, tentou-se realizar um passo intermediário para a realização do projeto: criar o modelo com uma classe de detecção para suínos.



Fonte: Os autores

Para a criação desse modelo, foi necessário o uso de diversas imagens de porcos individualmente e em rebanhos. Para esse processo, foi utilizado o banco de imagens Open Images Dataset V7, um conjunto de dados em larga escala pertencente ao Google que conta com mais de nove milhões de imagens para treinamento de detecção de objetos (HOFESMANN, 2021). Cada objeto vem previamente delimitado manualmente, a fim de gerar uma maior precisão no treinamento, conforme ilustrado na Figura 5.

Figura 5: Exemplos de imagens utilizadas no treinamento



Fonte: Open Images Dataset

Após a criação de um banco de imagens apropriado para o projeto, utilizando apenas imagens de suínos em condições semelhantes às estudadas, foi utilizada a biblioteca *TensorFlow Lite Model Maker*. Com ela, é possível realizar o treinamento para detecção de objetos de uma maneira simples e eficiente com o conjunto de



dados personalizado montado anteriormente. Foi utilizada a plataforma *Google Colab* a fim de executar o treinamento em máquinas com poder de processamento maior que o de um computador pessoal.

Em seguida da criação desse modelo e realização de testes, foram descobertas diversas incompatibilidades em relação ao código principal. Após análise, percebeu-se diferenças entre a ordem dos parâmetros de saída, bem como a estrutura interna dos modelos. A Figura 6 mostra alguns parâmetros internos dos dois modelos analisados pelo software Netron (à esquerda, o modelo inicial e à direita, o modelo criado), concluiu-se que todo o código deveria ser reestruturado para a criação de um modelo compatível com o código.

Figura 6: Comparativo entre os modelos

h_scale	5	h_scale	1
max_classes_per...	1	max_classes_per...	1
max_detections	10	max_detections	25
nms_iou_thresh...	0.6000000238418579	nms_iou_thresh...	0.5
nms_score_thres...	9.99999993922529e-9	nms_score_thres...	-Infinity
num_classes	90	num_classes	5
w_scale	5	use_regular_nms	0
x_scale	10	w_scale	1
y_scale	10	x_scale	1
_output_quantiz...	true	y_scale	1
<b>INPUTS</b>		<b>INPUTS</b>	
1	name: Squeeze	1	name: tf.nn.dequantize
2	name: convert_scores	2	name: Sigmoid1
3	name: anchors	3	name: stack
<b>OUTPUTS</b>		<b>OUTPUTS</b>	
0	name: TFLite_Detection_PostProcess	0	name: StatefulPartitionedCall:3
1	name: TFLite_Detection_PostProcess:1	1	name: StatefulPartitionedCall:2
2	name: TFLite_Detection_PostProcess:2	2	name: StatefulPartitionedCall:1
3	name: TFLite_Detection_PostProcess:3	3	name: StatefulPartitionedCall:0

Fonte: Os autores

Devido à complexidade desse processo e à incerteza dos resultados, optou-se por trocar a identificação dos animais semelhantes aos estudados, como vacas, ovelhas e cachorros (como mostrado na Figura 7), considerando que não se espera a existência

desses animais no interior do espaço reservado aos suínos. Mediante essa modificação, chegamos ao seguinte resultado:



Fonte: Os autores

Após essa alteração, criamos duas equações que medem o ponto médio das coordenadas de cada detecção para os eixos x e y. Essas equações utilizam os dois pontos opostos do objeto detectado para calcular um ponto central para utilizá-lo como referência de cada detecção.

$$x_c = (x_1 + x_2) \div 2$$

$$y_c = (y_1 + y_2) \div 2$$

Com isso, é realizado o cálculo da distância entre cada coordenada e um ponto fixo, correspondente ao centro das coordenadas do alimentador. Para isso, utilizamos a seguinte equação:

$$d = \sqrt{(x_a - x_c)^2 + (y_a - y_c)^2}$$

A distância entre animal e alimentador é definida pela incógnita “d” e os valores “ $x_c$ ” e “ $y_c$ ” e “ $x_a$ ” e “ $y_a$ ” definem, respectivamente, as coordenadas centrais de animal e alimentador. Ambos os valores possuem como unidade o pixel, a qual é a menor unidade que compõe uma imagem digital, independente de sua fonte.

Com isso, foi possível inferir se os animais estão próximos ou distantes do cocho de alimentação e, a partir da comparação dessa distância com um raio definido empiricamente delimitado ao redor do alimentador. A partir dessa informação, pode-se



considerar que, se um indivíduo está próximo ao cocho, há alta probabilidade de que este esteja se alimentando. Foram adicionados comandos para exportar as informações de cada detecção em um arquivo de texto externo.

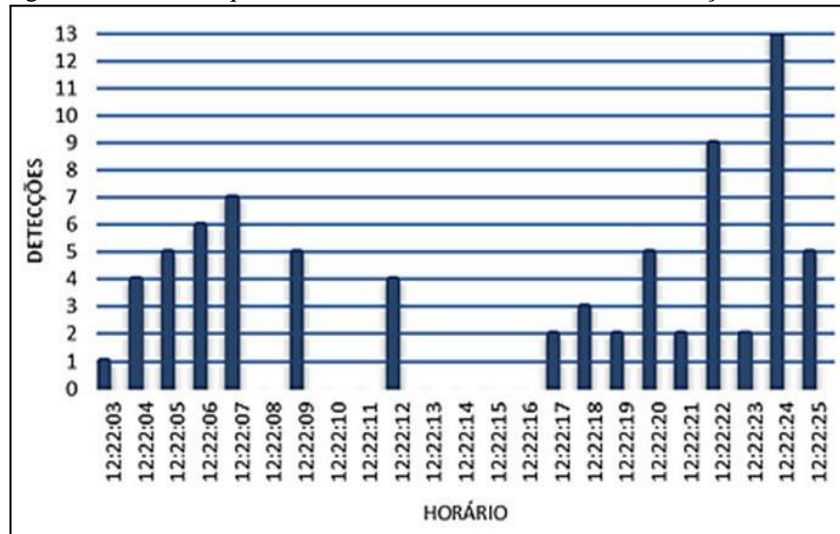
Para os estudos finais, foram utilizadas as informações extraídas, como se o indivíduo está se alimentando ou não e o tempo em que ele passa executando essa ação. Dessa forma, informações como o número de detecções padrão do modelo utilizado, pontuação de cada detecção e as respectivas classes e coordenadas foram descartadas do relatório.

Posteriormente, os dados foram exportados para uma planilha no LibreOffice utilizando um macro para que ela atualize periódica e automaticamente. Com isso, tornou-se possível elaborar um gráfico de atualizações constantes com essas informações para melhor visualização e análise dos dados.

#### **4 RESULTADOS E DISCUSSÃO**

O sistema foi testado utilizando vídeos de animais em seu convívio típico em uma baia com um cocho comum. Foi possível realizar a detecção dos animais no espaço de alimentação e, com isso, realizar o registro alimentar deles. Com as informações de detecção sendo exportadas pelo software e processadas pelo macro da planilha, foi possível gerar o gráfico da Figura 8 e um trecho de relatório da Figura 9.

Figura 8: Gráfico da quantidade de animais se alimentando em função do horário



Fonte: Os autores

Figura 9: Relatórios de duas diferentes detecções

Wed Nov 23 12:22:03 2022

i: 0

num detections: 10

detection scores: 0.644

detection classes: 17

detection locations:

xc: 283

yc: 189

d: 98

O ANIMAL ESTÁ SE ALIMENTANDO

Wed Nov 23 12:22:03 2022

i: 1

num detections: 10

detection scores: 0.632

detection classes: 19

detection locations:

xc: 83

yc: 197

d: 170

O ANIMAL NÃO ESTÁ SE ALIMENTANDO

Fonte: Os autores

Partindo para a análise, é possível observar que o número de detecções de animais em estado de alimentação variou bastante em um pequeno espaço de tempo, sendo o instante 12:22:24 o ápice do número de detecções. Com isso, concluímos que essas informações ainda não são suficientes para identificar um padrão na alimentação dos indivíduos, tornando-se necessários aprimoramentos para uma maior precisão do estudo.

O projeto prosseguirá em desenvolvimento por outra equipe de estudantes. Para perspectivas futuras e aprimoramento do estudo, é possível se criar o rastreo individual para os suínos, a fim de criar relatórios de alimentação mais precisos. Tal procedimento pode ser realizado pelo comparativo das coordenadas de cada detecção em intervalos curtos de tempo, bem como pela utilização de bibliotecas e fórmulas capazes de executar essa função. Outro avanço possível é criar uma forma de encontrar o alimentador por meio da detecção de objetos, facilitando a implementação do projeto.

## **5 CONCLUSÕES**

Mediante os resultados obtidos, notamos que é viável realizar a detecção de animais em estado de confinamento em grupos por meio da visão computacional, utilizando de um dispositivo compacto e de instalação simples, sem que haja contato físico com os animais. A partir de adaptações e aprimoramentos no protótipo, torna-se possível gerar relatórios e gráficos do comportamento alimentar de cada indivíduo a fim de encontrar padrões e, consequentemente, anormalidades nesse hábito. Futuros aprimoramentos incluem a geração de modelos específicos para suínos e evolução do algoritmo de rastreamento individual.

## **AGRADECIMENTOS**

Os autores agradecem ao Instituto Federal do Paraná, IFPR, pelo apoio na realização desse trabalho.

## REFERÊNCIAS

IMI, M. A.; KAMARU ZAMAN, F. H. **Vehicle Detection and Tracking using YOLO and DeepSORT**. Disponível em: <<https://ieeexplore.ieee.org/abstract/document/9431784>>. Acesso em: 30 de jul. 2022.

BROWN-BRANDL, T. M.; ROHRER, G. A.; EIGENBERG, R. A. **Analysis of feeding behavior of group housed growing–finishing pigs**. Computers and Electronics in Agriculture, v. 96, p. 246–252, ago. 2013.

BUGHIN, J. et al. **ARTIFICIAL INTELLIGENCE THE NEXT DIGITAL FRONTIER?**. Disponível em: <<https://www.calpers.ca.gov/docs/board-agendas/201801/full/day1/06-technology-background.pdf>>. Acesso em: 3 de ago. de 2022.

CHECHLIŃSKI, Ł.; SIEMIĄTKOWSKA, B.; MAJEWSKI, M. **A System for Weeds and Crops Identification—Reaching over 10 FPS on Raspberry Pi with the Usage of MobileNets, DenseNet and Custom Modifications**. Sensors, v. 19, n. 17, p. 3787, 31 ago. 2019.

CROSS, A. J. et al. **Feeding behavior of grow-finish swine and the impacts of heat stress**. Translational Animal Science, v. 4, n. 2, p. 986–992, 27 fev. 2020.

DE MILANO, Danilo; HONORATO, Luciano Barrozo. **Visão computacional**. Faculdade de Tecnologia, Universidade Estadual de Campinas, 2010.

HARTAWAN, D. R.; PURBOYO, T. W.; SETIANINGSIH, C. **Disaster Victims Detection System Using Convolutional Neural Network (CNN) Method**. Disponível em: <<https://ieeexplore.ieee.org/abstract/document/8784782>>. Acesso em: 29 de jul. de 2022.

HOFESMANN, Eric. **Google’s Open Images: Now easier to download and evaluate with FiftyOne**. Towards Data Science, 2021. Disponível em: <<https://towardsdatascience.com/googles-open-images-now-easier-to-download-and-evaluate-with-fiftyone-615ce0482c02>>. Acesso em: 29 de nov. de 2022.

KUZMIC, Jurij; RUDOLPH, Günter. **Object Detection with TensorFlow on Hardware with Limited Resources for Low-power IoT Devices**. In: IJCCI. 2021. p. 302-309.

LI, Q. **Application of Artificial Intelligence in Industrial Automation Control System**. IOP Conference Series: Earth and Environmental Science, v. 647, p.1-5, 27 jan. 2021.

MARENGONI, M.; STRINGHINI, S. **Tutorial: Introdução à Visão Computacional usando OpenCV**. Revista de Informática Teórica e Aplicada, v. 16, n. 1, p. 125–160, 8 mar. 2010.

MASELYNE, J. et al. **Methods to construct feeding visits from RFID registrations of growing-finishing pigs at the feed trough.** Computers and Electronics in Agriculture, v. 128, p. 9–19, 1 out. 2016.

NORMAN, M. et al. **Detection of in-Car-Abandoned Children via Deep Learning.** In: IOP Conference Series: Earth and Environmental Science. IOP Publishing, 2022. p. 1-7.

Google Inc. **OPEN IMAGES DATASET V7.** Disponível em: <<https://storage.googleapis.com/openimages/web/index.html>>. Acesso em: 26 de out. de 2022.

RAIMUNDO, A.; SEBASTIÃO, P. **Novos modelos de negócio com recurso à inteligência artificial.** IAPMEI, 2021. Disponível em: <Novos-modelos-de-negocio-com-recurso-a-Inteligenci.aspx (iapmei.pt)>. Acesso em: 3 de ago. de 2022.

Tecmundo. **Raspberry Pi: conheça os principais modelos.** Disponível em: <<https://www.tecmundo.com.br/produto/234771-raspberry-pi-conheca-principais-modelos.htm>>. Acesso em: 25 de jul. de 2022.

SANTOSO, S. A.; JAYA, I.; IQBAL, M. **Design and Implementation of Chaetodontidae Fish Identification Algorithms with Deep Learning Methods.** In: 2021 IEEE Ocean Engineering Technology and Innovation Conference: Ocean Observation, Technology and Innovation in Support of Ocean Decade of Science (OETIC). IEEE, 2021. p. 39-44.

TECHMOB. **O que é Raspberry Pi e para que serve?** Disponível em: <<https://techmob.com.br/o-que-e-raspberry-pi-e-para-que-serve/>>. Acesso em: 25 de jul. de 2022.

TELLES, E. S.; BARONE, D. A. C.; DA SILVA, A. M. **Inteligência Artificial no Contexto da Indústria 4.0.** Anais do Workshop sobre as Implicações da Computação na Sociedad (WICS 2020), 30 jun. 2020.

YOUNG, R. J.; LAWRENCE, A. B. **Feeding behaviour of pigs in groups monitored by a computerized feeding system.** Animal Science, v. 58, n. 1, p. 145-152, 1994.

EMBRAPA. **Resultados e impactos positivos da pesquisa agropecuária na economia, no meio ambiente e na mesa do brasileiro.** Disponível em: <<https://www.embrapa.br/grandes-contribuicoes-para-a-agricultura-brasileira-pecuaria>>. Acesso em: 25 de jul. de 2022.

ZHANG, L. et al. **Automatic Individual Pig Detection and Tracking in Pig Farms.** 2019.